

Algoritmi de Clasificare pentru Sisteme Big Data

Roșu Mihai-Cosmin - GMRV2

Facultatea de Automatică și Calculatoare

Universitatea Națională de Știință și Tehnologie Politehnica București

Rezumat

Creșterea exponențială a cantității de date generate de sistemele digitale moderne a dus la necesitatea unor algoritmi de clasificare eficienți și scalabili. Algoritmii tradiționali de machine learning, concepuți pentru medii centralizate, întâmpină dificultăți din cauza volumului seturilor de date contemporane. Acest eseu oferă o prezentare generală a algoritmilor de clasificare pentru sistemele Big Data, cu accent pe adaptarea acestora în sisteme distribuite precum Hadoop MapReduce sau Apache Spark. Metodele de învățare prin ansamblu, clasificatorii probabilistici, modelele liniare și algoritmii bazați pe rețele neurale sunt analizați din punct de vedere al scalabilității, acurateții și a eficienței computaționale. Folosind evaluări empirice recente, studii comparative și literatură de specialitate, acest eseu prezintă cum caracteristicile datelor, mai exact eterogenitatea dintre domeniile structurate și nestructurate, influențează semnificativ selecția algoritmilor. Discuția arată că nu există un singur clasificator care să domine toate scenariile, în schimb clasificarea datelor de dimensiuni mari necesită un echilibru între performanță, consum de resurse și implementarea arhitecturii.

1 Introducere

Creșterea rapidă a dimensiunii datelor generate de aplicații web, senzori, dispozitive mobile și întreprinderi a dus la apariția Big Data, caracterizat de cele 5 V-uri: volum, viteză, varietate, veracitate și valoare. Una dintre cele mai importante teme analitice în mediile big data este clasificarea, care are ca scop asignarea instanțelor de date în categorii predefinite. Clasificarea în contextul big data prezintă provocări noi, pe care algoritmii tradiționali de machine learning nu le pot adresa. Aceste provocări au motivat implementarea și adaptarea de algoritmi de clasificare care sunt scalabili, distribuiți și eficienți când sunt folosiți pentru platforme big data precum Hadoop și Apache Spark [2].

Acest eseu aduce în discuție algoritmii de clasificare principali folosiți în sistemele big data, accentul fiind pus pe principiile algoritmilor, caracteristicile scalabilității și compromisurile făcute pentru performanță. Bazat pe studii comparative, evaluări de performanță și literatură de specialitate, prezintă modul în care metodele de învățare prin ansamblu, clasificatorii probabilistici și tehnicile de machine learning în sisteme distribuite domină soluțiile de clasificare moderne folosite în sisteme big data [5].

2 Provocări în clasificarea Big Data

Clasificarea datelor de dimensiuni mari diferă semnificativ față de clasificarea convențională. În primul rând, volumul de date de multe ori depășește capacitatea unei singure mașini, motiv pentru care necesită stocare distribuită și procesare paralelă. În al doilea rând, viteza implică procesare în timp real sau iterativă, care cauzează arhitecturile bazate pe disc să fie ineficiente. În al treilea rând, varietatea datelor introduce caracteristici eterogene precum text, imagini și date numerice, ceea ce complică extragerea de caracteristici și crearea modelului. În final, scalabilitatea și toleranța la defecte sunt esențiale, fiindcă sistemele big data trebuie să funcționeze în mod fiabil pe diferite grupuri de hardware [2].

Pentru a adresa provocările, algoritmi de clasificare trebuie să fie paralelizabili, robuste la zgomot și dezechilibru și capabili de compromisuri de acuratețe pentru cost computațional. Astfel, mulți algoritmi tradiționali au fost reproiectați sau integrați în arhitecturi distribuite folosind paradigme precum MapReduce și procesare in-memory, mai exact Apache Spark.

3 Familii de algoritmi de clasificare pentru Big Data

3.1 Metode bazate pe învățarea în ansamblu

Dintre toate familiile, metodele bazate pe învățarea în ansamblu, în particular Random Forests și Gradien Boosting Machines (GBM), au demonstrat constant performanțe bune pe seturi de date mari. Random Forests combină mulți arbori de decizie antrenați pe subseturi de date alese aleator, ceea ce le face paralelizabile. Fiecare arbore poate fi antrenat independent, ceea ce se potrivește cu mediile distribuite precum Spark MLlib [4].

3.2 Support Vector Machines și modele liniare

Support Vector Machines (SVM), mai exact cei cu funcții radiale sau liniare pentru kernel, rămân o metodă de clasificare competitivă. SVM-urile liniare scalează în seturile de date mari și sunt folosite în clasificarea de text și de date de dimensiuni mari. Totuși, SVM-urile bazate pe kernel se lovesc de probleme de scalabilitate din cauza complexității computaționale, necesitând aproximări sau strategii de paralelizare pentru a fi folosite în sisteme big data [5].

Modelele liniare regularizate, precum Logistic Regression și Sparse Linear Discriminant Analysis, sunt folosite des în mediile big data. Avantajele lor se află în interpretabilitate, timp de antrenare scurt și adaptarea la optimizări pentru medii distribuite. Deși puterea lor de prezicere este redusă, sunt des alese atunci când eficiența computațională este critică.

3.3 Clasificatori probabilistici

Naive Bayes este unul dintre cei mai folosiți clasificatori probabilistici din cauza simplității și costului computațional redus. Presupunerea lui de caracteristici independente îi permite să scaleze eficient, în special în arhitecturi distribuite. Evaluările de performanță de pe grupuri de Spark demonstrează că Naive Bayes obține acuratețe ridicată cu un speedup favorabil [4].

3.4 Rețele neurale și Extreme Learning Machines

Clasificatorii bazați pe rețele neurale, incluzând Extreme Learning Machines (ELM) au fost adaptați pentru clasificarea volumelor mari de date. ELM-urile sunt folosite pentru că parametrii de pe nivele ascunse sunt inițializați aleator, ele optimizând doar ieșirile, astfel scăzând timpul de antrenare.

Deși învățarea profundă a început să devină populară în analiza volumelor mari de date, rețelele neurale tradiționale rămân relevante pentru sarcini precum clasificarea. Eficiența lor se bazează pe resursele computaționale disponibile și pe strategiile de paralelizare.

4 Evaluarea performanței în mediile Big Data

Dincolo de acuratețe, sistemele de clasificare big data trebuie să fie evaluate folosind metrici precum accelerarea (speedup), extinderea (scaleup) și mărirea dimensiunii (sizeup). Experimente făcute pe grupuri de Spark arată că performanța obținută prin adăugarea de noduri computaționale este de cele mai multe ori neliniară. De exemplu, clasificatorii Random Forest pot obține un scaleup optim la un număr mic de noduri, peste care comunicarea începe să reducă eficiența.

5 Tendințe de cercetare și provocări în desfășurare

Analize bazate pe studii arată că metodele bazate pe machine learning domină sistemele de clasificare, urmate de sisteme fuzzy, inteligența evoluționară și metode de învățare profundă. Publicațiile recente arată că eterogenitatea datelor, coexistența atributelor numerice structurate și a celor nestructurate precum text sau multimedia, este una dintre cele mai critice provocări aflate în desfășurare în clasificarea big data [3].

Studiile comparative din domenii structurate și nestructurate arată că modelele liniare optimizate și metodele de învățare în ansamblu bazate pe arbori de cele mai multe ori au rezultate mai bune decât arhitecturile profunde, în timp ce învățarea prin reprezentare și ingineria caracteristicilor reprezintă un factor decisiv în aplicațiile cu mult text [3]. Aceste descoperiri susțin ideea că doar complexitatea algoritmică nu garantează performanțe mai bune în condițiile big data.

O altă direcție de cercetare cuprinde proiectarea de infrastructuri scalabile. Sistemele de clasificare bazate pe MapReduce oferă o accelerare semnificativă cu cât volumul de date crește, dar prezintă și rezultate negative odată cu depășirea unui prag în dimensiunea grupurilor din cauza comunicării și coordonării [1]. În consecință, alegerea unui algoritm trebuie să țină cont nu numai de caracteristicile datelor, dar și de arhitectura distribuită pe care rulează.

6 Concluzii

Algoritmii de clasificare pentru sistemele big data au evoluat cu scopul de a adresa provocările computaționale și structurale create datorită seturilor de date masive. Metodele de învățare prin ansamblu precum Random Forests și GBM oferă în mod constant rezultate bune, în timp ce clasificatorii probabilistici precum Naive Bayes au o scalabilitate excelentă în cadrul mediilor distribuite. Modelele liniare, SVM-urile și metodele bazate pe rețele neurale adaugă varietate în cadrul algoritmilor, fiecare având compromisuri între acuratețe și eficiență.

Așadar, clasificarea eficientă în contextul big data necesită o abordare holistică care consideră atât performanța algoritmilor, cât și constrângerile de la nivelul sistemului. Fiindcă volumul de

date continuă să crească, cercetarea se concentrează pe tehnici de clasificare adaptive, scalabile și interpretabile care să beneficieze în totalitate de platformele distribuite moderne.

Bibliografie

- [1] Victor Ayma et al., “Classification Algorithms for Big Data Analysis, a Map Reduce Approach”, în *ISPRS - International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences XL-3/W2* (Mar. 2015), pp. 17–21, DOI: 10.5194/isprsarchives-XL-3-W2-17-2015.
- [2] N Srinivasu Chitrakant Banchhor, “A survey of big data classification strategies”, în *Control and Cybernetics* 49 (2020), pp. 447–469.
- [3] Jesus-Eduardo Gonzalez-Trigueros et al., “Challenges of Heterogeneity in Big Data: A Comparative Study of Classification in Large-Scale Structured and Unstructured Domains”, în (Nov. 2025), DOI: 10.48550/arXiv.2512.00298.
- [4] Mo Hai, You Zhang și Yuejin Zhang, “A Performance Evaluation of Classification Algorithms for Big Data”, în *Procedia Computer Science* 122 (Ian. 2017), pp. 1100–1107, DOI: 10.1016/j.procs.2017.11.479.
- [5] Jacques Wainer, “Comparison of 14 different families of classification algorithms on 115 binary datasets”, în (Iun. 2016), DOI: 10.48550/arXiv.1606.00930.