
ROLUL BIG DATA ÎN SISTEMELE DE RECOMANDARE ȘI INTELIGENȚA ARTIFICIALĂ GENERATIVĂ



Blogu Adrian-Toma - GMRV 2

Facultatea de Automatică și Calculatoare

Universitatea Națională de Știință și Tehnologie Politehnica București

REZUMAT

Creșterea exponențială a volumului de date colectate în mediile digitale a transformat fundamental modul în care sunt dezvoltate sistemele de recomandare și modelele de inteligență artificială generativă. Acest eseu examinează modul în care Big Data acționează ca un factor catalizator în aceste două domenii: pe de o parte, volumele masive de date permit sistemelor de recomandare să personalizeze conținutul la scară globală, iar pe de altă parte stau la baza noilor modele generative capabile să creeze conținut original (texte, imagini, muzică) de o complexitate fără precedent. Eseul abordează adaptările tehnologice – de la infrastructuri de calcul distribuite la algoritmi scalabili – ce fac posibile procesarea și analizarea acestor seturi uriașe de date. Sunt prezentate atât beneficiile (precum acuratețe sporită și capacitatea de a surprinde tipare subtile), cât și provocările apărute (cum ar fi sparsitatea datelor, calitatea și diversitatea informației, costurile computaționale și probleme etice). Analiza evidențiază că, deși volumul mare de date este esențial pentru performanța sistemelor moderne de recomandare și a modelelor de Inteligență Artificială Generativă (IAG), valoarea sa depinde în mare măsură de calitatea datelor și de capacitatea noastră de a le valorifica eficient. Big Data reprezintă fundația pe care se sprijină personalizarea avansată și generarea automată de conținut, însă pentru a obține rezultate optime este necesar un echilibru între cantitatea de date, diversitatea lor și metodele algoritmice folosite.

1 Introducere

Conceptul de Big Data se referă la volume masive de informații, caracterizate în mod clasic prin cele 4V: volum, varietate, viteză și veridicitate [5] (literatura de specialitate adaugă adesea și valoarea ca a cincea caracteristică). Aceste date uriașe sunt generate în ritm accelerat de interacțiunile utilizatorilor pe web, rețele de senzori, dispozitive mobile, tranzacții comerciale etc. Apariția Big Data a permis aplicațiilor de machine learning și inteligență artificială (IA) să atingă niveluri de performanță imposibil de obținut anterior, însă a impus și provocări noi legate de stocare, procesare și analiză. Două domenii care au beneficiat major de pe urma revoluției Big Data sunt sistemele de recomandare și IA generativă.

Sistemele de recomandare există de peste două decenii, însă abundența datelor moderne (de exemplu, istoricul de cumpărături, evaluările utilizatorilor, click-urile și preferințele exprimate online) le-a transformat din simple instrumente de filtrare în motoare sofisticate de personalizare. Marile companii tehnologice (precum Amazon, YouTube, Netflix) se bazează intensiv pe asemenea sisteme pentru a îmbunătăți experiența utilizatorilor și a genera venituri semnificative [5]. Spre exemplu, algoritmul de recomandare al Amazon personalizează pagina fiecărui client pe baza comportamentului

anterior, iar Netflix atribuie peste 75% din conținutul vizionat direct sistemului său de recomandări, cu un impact masiv în retenția abonaților. În era Big Data, sistemele de recomandare au devenit omniprezente, fiind integrate în aproape orice platformă digitală care oferă conținut sau produse, de la servicii de streaming de muzică/filme până la comerț electronic și rețele sociale [5].

IA generativă se referă la categoria de modele și algoritmi capabili să genereze conținut nou – text, imagini, audio sau date sintetice – cu un grad mare de autenticitate. Dezvoltarea acestor modele a cunoscut un salt spectaculos odată cu disponibilitatea Big Data. Practic, modelele generative de ultimă generație (precum large language models sau rețelele generative adversariale) datorează succesul accesului la seturi uriașe de date de antrenament. Un exemplu emblematic este modelul de limbaj OpenAI GPT-3, antrenat pe aproape 45 de terabytes de date text (aprox. 500 miliarde de cuvinte) și dispunând de 175 de miliarde de parametri [1]. Performanța acestor modele crește odată cu volumul de date: în general, cu cât un model este expus la mai multe exemple din lumea reală, cu atât va învăța tipare mai fine și va produce rezultate mai fluente și relevante. Evoluțiile recente în IAG – de la generarea de imagini fotorealiste la compoziție muzicală automată – demonstrează clar efectul Big Data: modele precum Stable Diffusion (pentru imagini) au fost antrenate pe miliarde de perechi imagine-text din setul LAION-5B [4], iar sisteme ca OpenAI Jukebox (pentru muzică) au în spate 1,2 milioane de melodii folosite la antrenament [3]. Fără aceste volume fără precedent de date, capacitățile creative ale IAG ar fi fost severe limitate.

În acest context, următoarele secțiuni vor detalia rolul concret al Big Data în cele două domenii menționate.

2 Big Data în Sistemele de Recomandare

Sistemele de recomandare au ca scop prezicerea preferințelor utilizatorilor și furnizarea de recomandări personalizate pentru produse, servicii sau conținut digital [5]. Tradițional, aceste sisteme se bazau pe volume relativ mici de date – de exemplu, istoricul de evaluări al unui utilizator sau a câtorva utilizatori similari – și întâmpinau limitări în scalare. În era Big Data însă, volumul de date disponibil a crescut enorm: milioane de utilizatori interacționează zilnic cu platforme online, generând fluxuri de date despre comportamentul lor (clicuri, vizionări, achiziții, aprecieri, recenzii etc.). Aceste date bogate și diversificate au sporit considerabil acuratețea sistemelor de recomandare, deoarece permit captarea unor tipare mult mai nuanțate despre gusturile și nevoile individuale.

Rolul central al Big Data în recomandări se manifestă în câteva moduri principale. În primul rând, cantitatea de date face posibilă antrenarea de modele mai complexe care necesită seturi mari pentru a evita supraînvățarea și pentru a generaliza bine. De exemplu, un algoritm modern de filtrare colaborativă poate exploata matrice uriașe utilizator–obiect (cu milioane de intrări) pentru a identifica corelații subtile între preferințele utilizatorilor [5]. Mai multe studii arată că eficiența sistemelor de recomandare crește odată cu volumul datelor: Netflix a constatat că adăugarea datelor despre vizionările utilizatorilor și evaluările acordate îmbunătățește semnificativ modelul de predicție a ratingurilor, reducând eroarea și măbind satisfacția utilizatorilor. De altfel, companiile raportează beneficii economice directe [5]. Un exemplu notabil: Netflix atribuie economii de peste 1 miliard USD anual sistemului său de recomandare, datorită reducerii dezabonărilor (churn) și creșterii timpului de vizionare per utilizator – conferind companiei un avantaj competitiv considerabil.

Al doilea aspect este varietatea datelor. Big Data nu înseamnă doar multe observații de același tip, ci și date eterogene. În sistemele de recomandare moderne, sursele de date includ atât atribute structurate (de exemplu, istoricul tranzacțiilor, demografia utilizatorilor, metadata despre produse) cât și nestructurate (review-uri text, comportament de navigare, conținut multimedia apreciat). Integrarea acestor surse diverse îmbunătățește calitatea recomandărilor – de pildă, combinarea evaluărilor numerice cu analiza sentimentului din recenzii text poate oferi o imagine mai completă asupra opiniei unui utilizator despre un produs. Însă această varietate vine la pachet cu provocări: datele nestructurate necesită preprocesare (extragerea trăsăturilor relevante din text, imagini, audio).

Al treilea mod în care Big Data contribuie este viteza și actualitatea datelor. În prezent, sistemele de recomandare operează adesea în regim real-time sau aproape real-time, actualizând recomandările pe măsură ce utilizatorul interacționează cu platforma. Volumul mare de date ce sosește continuu (de exemplu log-urile de evenimente în aplicații mobile) impune arhitecturi de prelucrare în flux (stream processing) și algoritmi online, capabili să învețe incremental. Astfel, Big Data a condus la adoptarea pe scară largă a arhitecturilor de tip Lambda sau Kappa pentru sistemele

de recomandare, care combină procesarea batch (pentru modele globale recalibrate periodic pe întregul dataset) cu procesarea stream (pentru integrarea rapidă a celor mai noi date și ajustarea locală a predicțiilor) [5]. Un exemplu este modul în care Amazon generează în timp real secțiuni precum "Customers who bought X also bought Y", agregând tranzacțiile recente la modelul existent fără a-l reantrena de la zero.

Pentru a valorifica pe deplin Big Data, sistemele de recomandare au trebuit și ele să evolueze din punct de vedere tehnologic. Scalabilitatea a devenit o cerință esențială. Multe librării de machine learning includ implementări paralele ale algoritmilor de recomandare (de ex. calculul matricilor de factorizare, nearest neighbors distribuit etc.). De asemenea, noile modele bazate pe învățare profundă (rețele neuronale) destinate recomandărilor (precum secvențiale de tip RNN/LSTM sau modele bazate pe transformers pentru recomandări de conținut) necesită atât volume mari de date pentru antrenament, cât și infrastructuri hardware puternice (GPU-uri, TPU-uri) care, la rândul lor, se aliniază filosofiei Big Data (distribuire și paralelizare pe scară largă).

Un aspect important legat de Big Data în recomandări este problema sparsității. Paradoxal, deși colectăm cantități enorme de date, matricea de interacțiuni utilizator-item este adesea foarte rară (sparse) – fiecare utilizator a evaluat/ofert feedback doar pentru o fracțiune minusculă din totalul item-urilor disponibile. Big Data însă oferă șansa de a atenua sparsitatea prin volum: într-o bază globală de utilizatori, chiar dacă fiecare vede doar puțin conținut, există suficientă suprapunere între preferințele grupurilor încât, statistic, se pot completa lacunele. Mai mult, multitudinea de attribute auxiliare (caracteristicile item-urilor, relațiile sociale între utilizatori, date demografice) pot acționa ca surse suplimentare pentru a îmbunătăți recomandările.

În concluzie, fără Big Data, servicii moderne precum recomandările muzicale (ex. Discover Weekly pe Spotify, care analizează miliarde de stream-uri pentru a găsi melodii noi potrivite gusturilor fiecărui utilizator) sau recomandările de filme (ex. Netflix, care analizează istoricul a peste 200 de milioane de abonați pentru a personaliza ecranul de întâmpinare) ar fi considerabil mai limitate ca performanță. Totodată, Big Data obligă la responsabilitate: sistemele de recomandare pot suferi de bias (de exemplu bias-ul din popularitate, unde item-urile deja populare primesc mai multe click-uri, deci sunt recomandate și mai mult, rezultatul fiind un efect de "rich get richer", conținutul nou sau de nișă moare), sau pot crea bule informaționale (efect de personalizare excesivă, unde sistemul servește aproape doar lucruri care confirmă preferințele existente).

3 Big Data în Inteligența Artificială Generativă

Inteligența Artificială Generativă (IAG) reprezintă clasa de tehnici de IA care pot crea conținut nou – texte coerente, imagini realiste, muzică sau chiar design de produse – pe baza învățării distribuției datelor existente. Practic, un model generativ învață caracteristicile setului de date pe care este antrenat și apoi poate genera exemple noi care par să provină din aceeași distribuție. Rolul Big Data în acest domeniu este fundamental, întrucât calitatea și diversitatea creațiilor unui model generativ depind direct de volumul și acoperirea datelor de antrenament. Deși algoritmi au suferit îmbunătățiri arhitecturale majore, multe din realizările recente au fost posibile în primul rând datorită disponibilității dataset-urilor masive și a resurselor computaționale proporționale.

Un exemplu notabil îl constituie modelele de limbaj de mari dimensiuni (LLM), cum este GPT-3. Acesta a fost antrenat pe aproape întreaga colecție de text a internetului (Common Crawl) plus cărți, articole Wikipedia, etc. Rezultatul este un model capabil să genereze text de o calitate uimitoare, demonstrând cunoștințe enciclopedice și abilități de a rezolva sarcini diverse (de la traducere la compunerea de cod) doar din pattern-urile învățate statistic. În plus, s-a observat o relație aproape monotonă: creșterea setului de date de antrenament (atunci când modelul are capacitate suficientă) duce la îmbunătățiri de performanță pe multiple tipuri de sarcini [1]. Desigur, există un prag de rentabilitate – beneficiile scad pe măsură ce datele devin din ce în ce mai multe, iar în practică apar limitări ce țin de costurile de antrenare și de calitatea datelor (nu tot textul de pe internet este util sau corect din punct de vedere factual).

Big Data joacă un rol similar și în alte ramuri ale IAG: generarea de imagini și generarea de muzică sunt exemple elocvente. Modelele difuzive precum DALL-E 2 sau Stable Diffusion au nevoie de seturi imense de imagini etichetate cu descrieri text pentru a învăța legătura dintre limbaj și imagine. LAION-5B, un dataset public de 5,85 miliarde perechi imagine-text, a fost creat tocmai pentru a permite antrenarea acestor modele la scară [4]. Stable Diffusion în particular a fost antrenat pe subseturi de ordinul miliardelor de imagini extrase din LAION, acoperind o varietate

enormă de subiecte, stiluri artistice, obiecte și scenarii. Similar, în muzică, OpenAI Jukebox (2020) demonstrează capacitatea de a genera piese audio cu voce și instrumente în diverse genuri; pentru a realiza aceasta, a fost necesar un corpus imens de 1,2 milioane de melodii împreună cu versurile și metadatele lor [3]. Modelul rezultat capturează distribuția complexă a sunetelor și poate produce cântece noi care, deși nu replică exact nicio melodie din datele de antrenament, împrumută stilul și caracteristicile statistic dominante din acestea.

Infrastructura Big Data este indispensabilă și în procesul de antrenare al modelelor generative. A gestiona zeci sau sute de terabyți de date de antrenament presupune atât putere de calcul masiv paralel (clustere de GPU-uri) cât și metode de optimizare sofisticate. Framework-urile de tip distributed learning (de ex. paralelizare pe date cu sincronizarea gradientului între mai multe noduri) au devenit standard în antrenarea modelelor IAG. De asemenea, stocarea și accesul eficient la date sunt esențiale: pipeline-urile de pregătire a datelor folosesc sisteme de fișiere distribuite (precum HDFS) sau baze de date optimizate pentru citire secvențială rapidă, astfel încât miliardele de exemple să poată fi streamuite în GPU fără să devină un bottleneck. În esență, Big Data și IAG au evoluat mână în mână: seturile de date din ce în ce mai mari au necesitat modele mai complexe și hardware scaling, iar la rândul lor aceste modele complexe sunt valide doar dacă au suficiente date pentru a-și exprima potențialul.

Un punct de dezbatere este calitatea vs. cantitatea datelor. Unii cercetători atrag atenția că nu orice mare volum de date este neapărat valoros. De exemplu, 10 TB de postări aleatorii de pe rețele sociale pot conține mult zgomot și informație redundantă/eronată, pe când un subset mult mai mic (de exemplu 1 TB) de date curatate cu grijă – cum ar fi articole verificabile din surse de încredere – pot conduce la un model generativ mai fiabil și mai factual [1]. De altfel, s-a ajuns la concluzia că “dimensiunea” Big Data optimă trebuie privită în tandem cu diversitatea și relevanța setului de date. Un volum mare de date omogene ar putea induce overfitting sau bias, pe când un volum ceva mai mic dar cuprinzând multiple domenii și stiluri poate oferi o bază de cunoștințe mai echilibrată. În practică, modelele ca ChatGPT (bazat pe GPT-3.5/GPT-4) sunt antrenate pe date filtrate, tocmai pentru a evita problemele menționate (informații false, toxicitate etc.). Cu toate acestea, factorul limitativ al celor mai noi modele ar putea deveni lipsa de date de calitate la scară suficientă, odată ce epuizăm resursele informative ușor accesibile online [1]. Asta sugerează că în viitor accentul se va muta de la colectarea cantității maxime de date la colectarea datelor potrivite pentru o anumită sarcină generativă – un subiect de cercetare activ (ex: data curation, prompt engineering cu feedback uman, generarea de date sintetice adiționale pentru a completa lacunele, etc.).

4 Provocări

Deși beneficiile aduse de Big Data în domeniul sistemelor de recomandare și al IAG sunt evidente, există o serie de provocări și limite.

O primă provocare este de ordin tehnologic și computațional. Prelucrarea seturilor masive de date necesare acestor sisteme implică costuri foarte ridicate de stocare și calcul. Antrenarea unui model generativ de vârf, cum ar fi GPT-4, necesită mii de GPU-uri lucrând în paralel timp de săptămâni, cu un consum energetic considerabil. Aceasta ridică probleme de sustenabilitate și accesibilitate [1]. Prin urmare, cercetarea academică se orientează fie spre partajarea modelelor pre-antrenate (fenomenul de foundation models open-source), fie spre găsirea de soluții de reducere a complexității. Se discută despre legi de scalare optime care să balanseze dimensiunea modelului cu cantitatea de date (caz în care modelul Chinchilla de la DeepMind a arătat că GPT-3, deși foarte mare, era antrenat pe mai puține date decât ar fi ideal, în timp ce un model mai mic antrenat pe mai multe date ar putea performa similar cu cost mai mic).

O a doua provocare majoră ține de calitatea datelor și implicațiile etice. Sistemele de recomandare alimentate de Big Data pot prelua și amplifica bias-urile din datele istorice. De exemplu, dacă datele reflectă o preferință pre-existentă doar către anumiți artiști, recomandările muzicale ar putea deveni inechitabile pentru artiști mai puțin cunoscuți (problemă de fairness). În IAG, datele de antrenament pot conține stereotipuri, limbaj indecent sau informații personale, pe care modelul generativ le-ar putea reproduce ulterior.

5 Concluzii

Big Data joacă un rol esențial atât în sistemele moderne de recomandare, cât și în inteligența artificială generativă, acționând ca un factor de amploare care a permis acestor tehnologii să atingă performanțe remarcabile. În sistemele de recomandare, volumele masive de date despre utilizatori și conținut au condus la un grad fără precedent de personalizare, demonstrându-și eficiența în creșterea satisfacției utilizatorilor. Datele abundente au permis abordări algoritmice mai sofisticate – de la filtrare colaborativă distribuită pe clustere Hadoop/Spark la modele hibride susținute de învățare profundă – toate menite să extragă semnal din zgomotul Big Data și să ofere recomandarea potrivită la momentul potrivit [5].

În domeniul inteligenței artificiale generative, Big Data s-a dovedit literalmente a fi materia primă a creativității mașinilor. Modelele de ultimă generație au „învățat” din colecții uriase de date – text, imagini, audio – reușind apoi să genereze conținut nou care imită cu fidelitate stilul și complexitatea lumii reale [1] [3]. S-a demonstrat astfel ceea ce unii autori numesc „eficacitatea neobișnuită a datelor”: atunci când algoritmi sunt simpli (de exemplu modele lingvistice de tip n-gram) și datele puține, progresul este limitat, dar pe măsură ce atât algoritmul, cât și datele cresc în complexitate și cantitate, apar proprietăți emergente care nu erau anticipate.

Bibliografie

- [1] IEEE Transmitter, *How Big Will AI Models Get?*, Feb. 2023, URL: <https://transmitter.ieee.org/how-big-will-ai-models-get/>.
- [2] R. H. R. Khan, “The Business Value of Generative AI and Big Data Integration: A Framework for Strategic Transformation”, în *Advances in Consumer Research* 5 (2025), pp. 550–556, URL: <https://acr-journal.com/article/the-business-value-of-generative-ai-and-big-data-integration-a-framework-for-strategic-transformation-1714/>.
- [3] OpenAI, *Jukebox: A Generative Model for Music*, Apr. 2020, URL: <https://openai.com/research/jukebox>.
- [4] P. Schuhmann et al., “LAION-5B: An open large-scale dataset for training next generation image-text models”, în *Proceedings of NeurIPS Datasets and Benchmarks*, 2022, URL: <https://arxiv.org/pdf/2210.08402>.
- [5] A. Sun și Y. Peng, *A Survey on Modern Recommendation System based on Big Data*, 2024, arXiv: 2206.02631, URL: <https://arxiv.org/pdf/2206.02631>.